

비판적 사고의 적용을 통한 LLM의 언어 이해 능력 개선 방안

백정범

인천 영선고등학교

The Method Improving LLM Language Understanding through the Application of Critical Thinking

JEONG-BEOM BAEK

Youngsun High School, Incheon, Korea

요 약 Large Language Models(LLM)은 현재 인공지능 분야에서 가장 주목 받는 모델로 지속적으로 발전하고 있다. 그러나, LLM은 여전히 언어 이해 능력을 비롯한 추론 능력, 정보 응용능력 등 여러면에서 한계를 드러내고 있다. 이러한 문제를 개선하기 위한 방안이 필요하다. 본 연구는 이러한 한계를 극복하기 위해 LLM의 언어 이해 능력을 개선하는 방안을 제시한다. 본 연구에서 LLM에 비판적 사고를 적용하면 언어 이해 능력을 비롯한 성능이 개선 될 것이라는 가설을 세우고 이를 입증하기 위한 실험을 설계 및 수행한다. 결과적으로 이러한 새로운 시도로 인하여 LLM 발전에 기여하고자 한다.

Abstract Large Language Model(LLM)s are currently among the most prominent models in the field of AI, continuously evolving and advancing. However, LLMs still face limitations in various areas, such as language comprehension, reasoning abilities, and the application of information. There is a need for strategies to address these issues. This study Proposes a method to improve the language comprehension capabilities of LLMs as a means to LLMs will enhance their language comprehension abilities and overall performance. To test this hypothesis, an experiment is designed and conducted. The ultimate goal of this new approach is to contribute to the development of LLMs

Key Words : Critical Thinking, Hypothesis, LLM, Language Understanding

1. 서론

대규모 언어 모델(LLM)은 최근 인공지능 분야에서 가장 주목받고 있는 모델 중 하나로, 빠르게 발전해 왔다. 현재 LLM은 기업의 고객 서비스, 개인의 정보 검색 도구 등등 다양한 분야에 널리 사용되며 주목받고 있으나, 아직 여러 문제를 내포하고 있다. 그중 대표적인 것은 언어 이해 능력에 관한 성능의 한계이다. 현재 이러한 한계를 개선하기 위한 LLM 성능 개선과 관련된 연구가 많지만, 아직 특정 상황에서 필요한 깊은 이해가 부족하다. 이러한 한계가 개선되지 않으면, LLM이 생성하는 답변에서 잘못된 정보를 전달하는 LLM의 환각 현상과 같은 오류가 일어날 수 있다. 이는 LLM

을 사용하는 개인과 기업에게 부정적인 영향을 미치며, 대화 효율성 저하와 신뢰성 감소를 초래할 수 있다.

언어 이해 능력 관련 LLM의 문제점으로 인해 생길 수 있는 결과를 요인별로 정리하면 다음과 같다.

- 토큰 방식(Token): LLM은 문장을 분석 할 때 토큰 방식을 사용하는데 토큰은 개수 제한이 있다. 이를 초과하거나 초점이 특정 토큰으로 맞춰지는 현상으로 인해서 응답이 끊기거나 프롬프트의 정보가 누락 되는 문제가 생긴다.[1,2,3]

- 데이터: LLM 작동 과정에서 처리 해야 하는 데이터가 너무 많거나 LLM의 데이터 다양성이

부족하면 부정확한 응답이 생성될 수 있다. 이는 LLM의 환각 현상으로 불리는 대표적인 문제이다.[3,4,5]

- 프롬프트: 프롬프트, 즉 입력되는 문장이 매우 길거나 난해하면 애매하거나 부정확한 응답이 생성되는 문제가 있다.

이를 통해 토큰과 데이터의 한계 그리고 LLM의 언어 응용 능력 부족이 오류 발생의 본질적인 이유가 됨을 알 수 있다. [6,7]

이러한 LLM이 가져올 수 있는 부정적인 영향과 오류들을 이유로 LLM의 언어 이해 능력 개선은 우리가 꼭 이뤄야 할 과제이다.

이와 같은 문제를 해결하기 위해 본 연구는 LLM의 언어 이해 능력의 개선을 목적으로 LLM의 언어 이해 능력에 영향을 주는 요인을 분석하고 이를 바탕으로 LLM을 개선할 수 있는 개선 방안을 도출하는 방향으로 연구를 진행하여 LLM의 발전으로 활용 가능성을 높이고자 한다.

2. 본론

2.1 관련 연구

2.1.1 stockfish(15.1) vs ChatGPT(3.5)[6]

LLM의 정보 응용 능력을 평가하기 위한 연구로 체스 엔진인 Stockfish와 ChatGPT간의 1000번의 체스 대결이 수행시켰다. (대결 당시 스톡피쉬와 GPT 모두 최신 버전이었다.) GPT는 체스 규칙에 대한 이해는 충분히 갖추고 있었지만, 이를 실제 대결에 적용하는 데에는 한계를 보

였다는 결과가 있었다. LLM이 추론을 요구하는 체스에서 취약한 모습을 보여[8] 현재 LLM이 프롬프트를 숙지하는 성능은 좋지만 숙지한 정보를 응용하는 능력이 떨어진다는 사실을 알 수 있다.

2.2. 성능 향상의 요인 분석

LLM(GPT)은 환각 증세[5]로 규칙을 어기는 수를 옳다고 판단하고 그 결과를 생성했기 때문에 LLM이 숙지한 정보를 실제 대결에 적용하는 것과 LLM의 언어 응용 능력에 한계가 있다는 것을 알 수 있다.[1,2,3,4] 또한 LLM이 언어 이해 능력 성능에 영향을 주는 추론에 한계가 있다는 것을 알 수 있다.[8,9,10,11,12] 이러한 결론과 아래의 성능 향상의 요인을 바탕으로 LLM의 언어 이해 능력을 개선 방안을 제시하는 방향으로 연구를 진행했다.

2.2.1 토큰

LLM은 문장을 분석 할 때 토큰 방식을 사용하는데 토큰은 LLM이 처리하는 텍스트의 기본 단위이다. 문장을 언어에 따라 단어, 어절, 기호와 같은 기준으로 끊어 여러 개의 토큰으로 나눌 수 있다. 나뉜 토큰은 문맥 이해, 토큰 예측, 학습, 내용 요약 등에 쓰이고 LLM이 응답 구성하고 각 토큰들을 연결하는 데에 쓰인다. 또한 토큰은 LLM이 문장을 숙지하고 분석하는 성능에 가장 큰 영향을 주기에 성능 향상에 큰 요인이 된다. 이러한 토큰과 관련된 문제를 개선하기 위해 토큰 제한 개수를 늘리거나 성능이 떨어지는 특정 언어를 위해 토큰으로 끊는 기준을 언어마다 지원하는 등 토큰 방식의 변형과 한계 극복 LLM이 프롬프트를 이해하는 성능을 개선할 수 있다.[1,2,3]

2.2.2 데이터

데이터는 LLM의 창의성에 큰 영향을 준다. 올바른 가치가 있는 데이터를 학습시키고 데이터의 다양성을 늘리면 LLM의 창의력 성능을 개선 하는 큰 요인이 될 수 있다.

2.2.3 프롬프트

프롬프트는 LLM이 수행할 수 있는 정보를 정해준다. LLM의 오류 발생의 원인 중 하나가 프롬프트의 난해함이다. 난해한 프롬프트를 통계를 통해 사용자의 요구를 판단할 수 있도록 LLM을 학습시킨다면 오류 발생을 줄일 수 있다. [3,4,5]

2.3 개선 방안 고안

위에 언급한 토큰 활용 방식을 다양화하거나 데이터의 다양성을 늘리는 등의 방법을 통해 LLM의 언어 이해 능력 성능이 개선될 수 있다. 그러나 이러한 방법만으로는 성능 개선에 한계가 있다. 따라서 LLM을 개선시킬 수 있는 새로운 방식을 고안했다. LLM의 언어 이해 능력을 개선하기 위해 인간의 언어, 논리적 능력 향상의 요인이 되는 비판적 사고를[12,13] 모방하여 적용하면 LLM의 언어 이해 능력 성능을 개선할 수 있다. 라는 가설을 세우고 이를 입증하는 방식으로 연구를 진행하였다.


2.3.1 비판적 사고 LLM

사람의 비판적 사고의 과정은 순서대로 정리하면 질문 제기, 정보 수집, 정보 분석, 추론, 판단, 피드백으로 구성된다[13,14]. LLM은 위의 사고 과정 중 질문 제기 ~ 정보 분석까지 수행할 수 있다. 지금의 LLM은 인간처럼 생각하지 않고 수리적인 추론과 상식적인 추론을 하기 때문에 [8] 복잡한 프롬프트를 다루기 위한 충분한 이해력이 없다. 또한 정보의 신뢰성이나 정확성을 제공할 때 스스로 판단할 수 없다[15,16,17,18]. 이러한 이유로 사람이 추론과 판단을 하는 방식을 적용했다. 사람은 추론과 판단을 할 때 스스로에게 "만약에"라는 질문을 하고 옳고 그름을 판단한다[19]. 위의 내용을 통해 LLM의 작동 방식을 변형시켜 프롬프트의 정보와 관련 데이터를 바탕으로 세울 수 있는 논리적인 모든 가설을 세우고 이를 입증하는 방식으로 작동하도록 하여 비판적 사고를 모방하여 적용할 수 있다고 판단했다.

2.3.2 적용 방법


LLM에 비판적 사고를 적용하는 방법은 LLM이 프롬프트를 토큰화하고 임베딩하며 문맥을 이해하고 즉시 응답 생성하는 기존의 작동 방식 대신 이해한 모든 정보를 바탕으로 생성할 수 있는 논리적인 모든 가설을 생성하고 이를 검증하며 가장 타당한 가설을 선택해 결론을 도출하여 답을 생성하는 방식으로 바꾸는 것이다. 이는 다양한 가능성을 염두하고 가장 타당한 것을 바탕으로 결론을 도출하는 사람의 비판적 사고를 LLM에 적용한 것이다.

[flowchart 1.]



(1) 기존의 방식

[flowchart 2.]



(2) 비판적 사고 방식

2.4 실험 진행

실험은 데이터셋 구축 이후 LLM을 구현하여 학습시키고 실험을 이행하는 방향으로 진행한다.

2.4.1 데이터셋 구축

LLM을 구현하려면 기본적으로 LLM을 학습시킬 데이터가 필요하다. 또한 한국어로 질의응답을 할 예정이기에 한국어 데이터로 수집하였다. 데이터는 LLM이 수행할 기본적인 자연어처리를 위한 텍스트 관련 데이터 50% 비판적 사고를 위한 논리적 추론 30% 문제 해결 20%로 수집하였다. LLM을 학습시킬 한국어 데이터셋 여러 개를 정제하고 병합하여 하나의 데이터셋으로 만드는 방향으로 merged-v2 데이터셋을 구축하였으며 이는 dictionary 구조로 instruction, input, output을 포함한 형식이다.

[fig. 1.]
merge-v2 데이터셋(hugging face)

instruction	input	output
string	lengths	lengths
3원세이만 무엇인가?		세 가지 기본 색은 빨강, 파랑, 노랑입니다. 이 색은 다른 색을 혼합하여 만들 수 있고 다른 모든 색은 ..
여러분 결정을 내려야 했던 순간을 설명해 주세요.		AI 어시스턴트인 저는 저만의 개인적인 경험이나 물리적 존재를 가지고 있지 않습니다. 하지만 알고리즘을...
항자의 구조를 설명합니다.		항자는 모든 물질의 기본 구성 요소이며 양성자, 중성자, 전자의 세 가지 유형의 입자로 이루어져 있습니다.
대기 오염을 줄이려면 어떻게 해야 할까요?		대기 오염을 줄이는 방법에는 다음과 같은 여러 가지가 있습니다: 1. 에너지 소비를 줄입니다: 에너지 효율적인...
건강을 유지하기 위한 세 가지 습을 알려주세요.		1. 균형 잡힌 영양가 있는 식단을 섭취합니다: 식단에 다양한 과일과 채소, 저지방 단백질, 통곡물, 건...
물리 공식을 찾아주세요.		물리 공식은 표준 대가입에서 섹터 1.88도 또는 화씨 212도입니다.

[Table 1.]
데이터셋 구성표

앞서 언급한 비율의 데이터를 정제하는 과정에서 텍스트 분석 50% 논리적 추론과 문제 해결이 각각 25%가 되었다.

Type \ Dataset	텍스트 분석	논리적 추론	문제 해결
KoMedInstruct-52k	X	O	O
instruction_korean	O	X	X
ko_alpaca_data.snappy	O	X	X
openhermes.train	O	X	X
koc_alpaca_data	O	X	X
pubmedQA_test_translated	X	O	O
kullm-v2	X	O	O
GenMedGP-5k	X	O	O

2.4.2 LLM 설명

현재 ChatGPT와 같은 큰 LLM을 구현하는 데 있어 컴퓨터 성능의 한계가 큰 장애물로 작용하고 있다. Unsloth AI는 LLM의 파인튜닝을 최적화하여, 일반적인 컴퓨터에서도 모델을 학습하고 실행할 수 있도록 지원한다. 아래는 unsloth와 transformers 같은

라이브러리와 모듈 등 다양한 툴을 이용했다. 본 연구는 컴퓨터 성능의 한계에 맞춰 효율에 집중하였다.

효율성을 이유로 웹에서 프로그래밍 할 수 있는 구글의 colab을 사용했으며 학습은 SFT방식으로 진행했다. max_steps는 60으로 설정했다. 파라미터를 효율적으로 학습하기 위해서 LoRA를 사용했으며.(모듈 q_proj, k_proj, o_proj 등) LoRA의 rank와 Alpha는 16으로 설정했다.[2,12]

메모리 효율성을 높이기 위해 Adamw optimizer(8bit)를 사용하였다. 이는 weight decay(= 0.01)를 더 효율적으로 적용할 수 있도록 한다. 또한 learning rate의 최대치를 2-e4로 설정하고 5%의 warm-up 코사인 스케줄러를 적용하여 안정적으로 학습할 수 있도록 하였다. Gradient accumulation을 4level로 설정하여 작은 batch를 여러 번 처리하도록 하여 큰 batch와 비슷한 결과를 얻을 수 있게 했다. 또한 4bit 양자화(파라미터 압축)을 통해 메모리 사용량을 최적화하여 더 큰 batch size와 긴 seq(시퀀스) 처리가 가능하게 했다. [12] 위의 설정이나 과정들은 대부분 Unsloth와 Transformers 라이브러리를 통해 성능, 효율을 최적화한다.

마지막으로 텍스트 생성 코드를 수정하여 비판적 사고를 적용했다.

[fig. 2.]
비판적 사고 모델(hugging face)

File Name	Size	Upload Date
gitattributes	1.57 KB	9 days ago
README.md	24 Bytes	9 days ago
config.json	993 Bytes	9 days ago
generation_config.json	234 Bytes	9 days ago
pytorch_model-00001-o...	4.97 GB	9 days ago
pytorch_model-00002-o...	1.46 GB	9 days ago
pytorch_model.bin.index.json	28.9 KB	9 days ago
special_tokens_map.json	454 Bytes	9 days ago
tokenizer.json	17.2 MB	9 days ago
tokenizer_config.json	54.6 KB	9 days ago

2.4.3 예상 결과

이처럼 LLM의 작동 방식을 인간의 비판적 사고와 유사하게 변형시키는 방법을 위의 연구에서 활용한 LLM이 아닌 더 성능이 좋은 컴퓨터에서 구현하고 더 많은 데이터를 학습한 LLM에 적용하게 된다면 예상 결과는 다음과 같다. 이 연구의 목적인 언어 이해 능력이 향상될 뿐만 아니라 가설을 세우는 과정에서 계속해서 스스로 학습하며 정보 응용 능력, 논리력을 강화할 수 있고, 스스로 정보의 신뢰성과 정확도를 판단할 수 있을 것이라는 결과를 기대 할 수 있다.

2.4.4 LLM 평가

LLM 평가는 직접 파인튜닝한 LLAMA3.2 3B 모델과 비판적 사고 모델의 답변을 비교 평가하는 방식으로 진행한다.

2.4.5실험 결과

모델을 평가하기 위한 문장들을 프롬프트에 입력하고 이에 따른 답변을 비교하였다. 다음은 문장의 예시이다. “각국의 법률에서는 정의라는 개념이 자주 등장하며, 법령의 형성과 해석에 있어 매우 중요한 부분을 차지한다. 하지만 정의란 명확히 규정할 수 없는 개념이기에 해석의 논란이 있을 수 있다. 그렇다면 사회구성원의 대다수가 납득할 수 있는 보편적 정의를 입증하는 방법은 무엇일지 생각해보아라.” 위의 문장은 보편적인 정의를 입증하는 방법을 요구하는 프롬프트이고, 이에 따른 모델들의 답변은 다음과 같다.

LLAMA: “정의는 명확히 규정할 수 없는 해석에 논란이 생길 수 있다. 보편적 정의를 입증하려면 정의를 규정하는 법령, 사회구성원들 공통의 이해와 의견 수집 같은 사회구성원의 노력과 협력이 필요하다.”라고 답변하며 보편적인 정의를 입증하기 위한 실행 방법을 제시하였고,

비판적 사고를 적용한 LLM: “정의를 구체화하는 방법은 사회구성원들이 합리적으로 수용할 수 있는 방식으로 수행될 수 있으며, 주요 방법은 각각 정의 간에 유사성과 비 유사성을 찾아 정의를 합리적으로 이해하고 수용할 수 있다.”라고 답변하며 정의를 사회구성원들에 맞춰서 정의하는 방법을 제시하였다.

다음은 기준에 따른 답변의 완성도에 따라 점수를 매기고 비교를 한 표이다.

[Table 2.]

LLAMA3.2 3B와 비판적 사고를 적용한 LLM 비교표

Score Model	언어 적합성	추론	질문 요구사항 충족 여부
LLAMA3.2 3B	5	3	6
Critical Thinking LLM	4	6	7

최종적으로 1.000점 만점에 LLAMA는 0.466점, 비판적 사고 LLM은 0.566점으로 실험 결과 “LLM에 비판적 사고를 적용하면 정보 응용, 추론, 언어 이해 능력 등 성능이 개선된다.”가 입증되었다.

3. 결론

3.1 연구 요약

본 연구는 LLM의 언어 이해와 같은 여러 성능이 부족하다는 한계를 개선하기 위해 LLM의 성능과 관련된 요인을 조사 및 분석하였고 이를 통해 토큰, 데이터 등 요인들을 통한 개선은 현재로서 할 수 없다는 결론을 내었다. 관련 연구를 찾아보며 LLM의 언어 이해 성능이 언어, 추론, 논리와 관련되어 있다는 것을 통해 인간의 언어 이해를 비롯한 추론과 논리, 판단 능력을 더 높일 수 있는 비판적 사고를 LLM의 적용하면 성능이 높아질 것이라는 가설을 세웠다. 이를 입증하는 실험을 진행하며 LLM의 성능을 높이는 방안을 고안했다. 이러한 실험을 진행하기 위해 일반적인 PC에서 LLM을 구현할 수 있도록 효율성을 극대화시켜 LLM 모델을 구현하였고 LLM이 작동하는 방식을 비판적 사고방식으로 바꿔 비교하는 형식으로 실험을 진행하였고, 결과적으로 개선이 된다는 것을 입증하였다.

3.2 한계와 향후 연구 동향

본 연구는 제한된 컴퓨터 성능과 부족한 한국어 데이터 등 부족한 환경에서 효율을 중시하며 실험을 진행했기에 또한 성능이 부족한 LLM의 성능을 개선 하였다고 하여 성능이 좋은 LLM이본 연구의 실험 결과처럼 분명한 개선이 되지 않을 수 있다. 하지만 관련 연구를 보며 논리적으로 가능한 방안을 고안하고 이를 입증하였기 때문에 향후 더 개선된 컴퓨터와 더 가치 있고 다양성이 높은 데이터셋등 좋은 환경에서 실험을 진행이 필요하다. 또한 모델의 성능평가가 선정된 일정 문장들로만 이루어졌기 때문에 LLM 관점에서 난해한 문장과 같은 다른 문제에 대한 추가적인 연구가 요구된다.

참고문헌

- [1] Iz Beltagy, Matthew E. Peters, & Angelina Cohan, "Longformer: The Long Document Transformer", University of Washington, 2020
- [2] Alp K. Katharopoulos, Miguel Dotiwalla, Andrei Beygelzimer, & Lihong Yang, "Reformer: The Efficient Transformer", ICLR, 2020
- [3] Jacob Devlin, Ming-Wei Chang, Kenton Lee, & Kristina Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding", Google AI Language, 2018
- [4] Michael Mosbach, Nick Agarwal, & Dmitriy Yarats, "Fine-tuning Pre-trained Language Models: Weight Initializations, Data Orders, and Early Stopping", not displayed, 2020
- [5] Emily M. Bender, Timnit Gebru, Angelina McMillan-Major, & Mark Bennett, "On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?", 2021
- [6] MT Kuo, CC Hsueh, Richard TH Tsai, "Large Language Models on the Chessboard: A Study on ChatGPT's Formal Language Comprehension and Complex Reasoning Skills", Journal of Chingshin Academy et 2 other places, pp. 1-4, 2023
- [7] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, & Illia Polosukhin, "Attention is All You Need", NIPS, 2017
- [8] Youngbin Noh, NCResearch, 2023, <https://ncsoft.github.io/ncresearch/d1d22308d4efe749b647a5ad2bc8e68bd71ccded>, 2024.11
- [9] Vinay Thorne, Emmanuel Vlachos, "A Survey on Automated Fact-Checking", University of Cambridge, 2020
- [10] Tolga Bolukbasi, Kai-Wei Chang, Jedidi Y. Zou, Venkatesh Saligrama, & A. T. Kalai, "Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings", Boston University et 1 other place, 2016
- [11] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, P. Dhariwal, & Dario Amodei, "Language Models are Few-Shot Learners", OPEN AI, 2020
- [12] Seungjun Lee, Taemin Lee, Jeongwoo Lee, Yoonna Jang, Heesok Lim, "구름(KULLM): Learning to Construct Korean Instruction-following Large Language Model", Proceedings of the 35th Annual Conference on Human and Cognitive Language Technology, 2023
- [13] Jinnam Yi, "Necessity of Critical Information Literacy Education", 사고와 표현(2021) vol.14 no.2 7-29, 2021
- [14] Pyoung Gu Baek, "Research Trends on Critical Thinking Using Topic Modeling", Korean Journal of General Education 2022. 6. Vol. 16, No. 3, PP. 11-27
- [15] Rachel Gordon, MIT News, 2024, <https://news.mit.edu/2024/reasoning-skills-large-language-models-often-overestimated-0711>, 2024.11
- [16] William James Bolton, Rafael Poyiadzi, Edward Morrell, Gabriela van Bergen Gonzalez Bueno, Lea Goetz, "RAmBLA: A framework for evaluating the reliability of LLMs as assistants in the biomedical domain", International Conference on Learning Representations, 2024
- [17] Mahmud Omar, Reem Agbareia, Benjamin S Glicksberg, Girish N Nadkarni, Eyal Klang, "Benchmarking LLM Self-Assessment in Clinical Scenarios", medRxiv, 2024
- [18] Jinman Zhao, Xueyan Zhang, "Exploring the Limitations of Large Language Models in Compositional Relation Reasoning", arXiv, 2024
- [19] Mark Alfano, "Moral reasoning is the process of asking moral questions and answering them", Behavioral and Brain Sciences, volume 42, 2019

백 정 범(JEONG-BEOM BAEK)



- 2022년 12월 : 인천진산중학교 졸업
- 2023년 3월~현재 : 인천영선고등학교 재학 중

<관심분야>

인공지능, 데이터분석, 소프트웨어